

ALG LAB6

王世烜 PB20151796
2022/11/19

Huffman 编码问题

实验内容

编程实现 Huffman 编码问题，并理解其核心思想。

对文件 `original.txt` 中所有的大小写字母、数字 (0-9) 以及标点符号（即：除空格 换行等之外的所有字符）按照 Huffman 编码方式编码为 01 序列，输出如下格式的 `table.txt` 文件, 并在控制台打印压缩率。

算法设计思路

首先，将所有的字符以及它们出现的频率存在结点中，并将这些结点放入优先队列，形成森林。

每一次将优先队列的前两个结点（频率最小的两个结点）出队，并合并成为一个新的结点，之后再将此结点加入优先队列，并维护优先队列的性质。

当优先队列中只剩下一个结点的时候，树便建立成功。

之后从根节点开始向下遍历，依次添加编码。

源码+注释

结点结构：

```
// Huffman树的节点类
typedef struct node
{
    char value;           //节点的字符值
    double freq;          //节点字符出现的频度
    vector<int> code;      //节点字符对应的编码
    node *lchild, *rchild; //节点的左右孩子
} HFMNode, *pHFMNode;
```

优先队列比较方法：

```
struct CMP
{
    bool operator()(const pHFMNode &p, const pHFMNode &q)
    {
        return p->freq > q->freq;
    }
};
```

建立哈夫曼树：

```
void Huffman(priority_queue<pHFMNode, vector<pHFMNode>, CMP> &vctNode)
{
    while (vctNode.size() > 1)
    {
        pHFMNode first = vctNode.top(); //取vctNode森林中频度最小的树根
        vctNode.pop();
        pHFMNode second = vctNode.top(); //取vctNode森林中频度第二小的树根
        vctNode.pop();
        pHFMNode merge = new HFMNode; //合并上面两个树
        merge->freq = first->freq + second->freq;
        merge->lchild = first; //小的放左子树
        merge->rchild = second; //大的放右子树
        vctNode.push(merge); //向vctNode森林中添加合并后的merge树
    }
    return;
}
```

输出编码：

```
void PrintHuffman(pHFMNode node, vector<int> &vctCode, ofstream &outfile)
{
    if ((node->lchild == NULL) && (node->rchild == NULL))
    {
        node->code.assign(vctCode.begin(), vctCode.end()); //复制vctCode到code
        outfile << node->value << "    " << left << setw(8) << node->freq;
        for (vector<int>::iterator iter = node->code.begin(); iter != node->code.end(); iter++)
        {
            outfile << *iter;
        }
        outfile << endl;
        code_length += vctCode.size() * node->freq;
    }
    else
    {
        vctCode.push_back(0); //遇到左子树时给vctCode中加一个0
        PrintHuffman(node->lchild, vctCode, outfile);
        vctCode.pop_back(); //回溯，删除刚刚加进去的1
        vctCode.push_back(1); //遇到右子树时给vctCode中加一个1
        PrintHuffman(node->rchild, vctCode, outfile);
        vctCode.pop_back(); //回溯，删除刚刚加进去的0
    }
    return;
}
```

算法测试结果

可得到编码如下：

字符	出现频率	编码
d	6281	0000
f	2878	00010
u	3428	00011
m	3494	00100
w	3518	00101
F	188	001100000
E	95	0011000010
R	49	00110000110
P	50	00110000111
"	391	00110001
M	197	001100100
1	5	00110010100000
2	1	0011001010000100
K	1	0011001010000101
3	3	001100101000011
X	3	001100101000100
7	1	0011001010001010
5	2	0011001010001011
4	4	001100101000110
Q	4	001100101000111
U	15	0011001010010
9	4	001100101001100
6	2	0011001010011010
0	2	0011001010011011
V	9	00110010100111
;	56	00110010101
!	112	0011001011
T	430	00110011
,	1938	001101
'	233	001110000
W	120	0011100010
j	120	0011100011
N	245	001110010
I	261	001110011
k	985	0011101
b	2029	001111
r	7643	0100
s	7685	0101
i	7886	0110
h	8491	0111
e	17214	100
n	9253	1010
p	2149	101100
y	2173	101101
x	274	101110000
B	280	101110001
H	141	1011100100
?	67	10111001010
G	18	1011100101100
(18	1011100101101
)	18	1011100101110
Y	21	1011100101111
-	292	101110011
v	1192	1011101
c	2663	101111
o	9890	1100
a	10834	1101
g	2761	111000
A	312	111001000
q	153	1110010010
C	160	1110010011
S	339	111001010
O	80	11100101100
:	40	111001011010
D	42	111001011011
z	45	111001011100
L	45	111001011101
J	93	11100101111
.	1512	1110011
l	5847	11101
t	11515	1111

压缩率： 0.641293